

Міністерство освіти і науки України
Національний технічний університет України
«Київський політехнічний інститут імені Ігоря Сікорського»
Фізико-технічний інститут

ЛАБОРАТОРНА РОБОТА №1
«Експериментальна оцінка ентропії на символ джерела відкритого тексту»

Виконала:
студентка групи ФБ-04
Андрійчук Анастасія
Перевірив:
Чорний О.

Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Порядок виконання роботи

0. Уважно прочитати методичні вказівки до виконання комп'ютерного практикуму.
1. Написати програми для підрахунку частот букв і частот біграм в тексті, а також підрахунку $1H$ та $2H$ за безпосереднім означенням. Підрахувати частоти букв та біграм, а також значення $1H$ та $2H$ на довільно обраному тексті російською мовою достатньої довжини (щонайменше 1Мб), де імовірності замінити відповідними частотами. Також одержати значення $1H$ та $2H$ на тому ж тексті, в якому вилучено всі пробіли.
2. За допомогою програми CoolPinkProgram оцінити значення $10(H)$, $20(H)$, $30(H)$.
3. Використовуючи отримані значення ентропії, оцінити надлишковість російської мови в різних моделях джерел

Хід роботи

Взяла текст «Преступление и наказание». Очистила текст від непотрібних символів. Далі за формулами порахувала частоти, ентропії, надлишковості. Отримані таблички зберегла через пандас в ексель.

Результат

Монограми з пробілами

ентропія 4.304284399234026

надлишковість 0.13914312015319474

Монограми без пробілів

ентропія 4.399966340633688

надлишковість 0.11187081315110559

Перехресні біграми з пробілами

ентропія 3.9279688039841756

надлишковість 0.21440623920316493

Неперехресні біграми з пробілами

ентропія 3.9273189639991983

надлишковість 0.2145362072001603

Перехресні біграми без пробілів

ентропія 4.101573507324395

надлишковість 0.17210113399723115

Неперехресні біграми без пробілів

ентропія 4.100124677867977

надлишковість 0.17239357889962237

Таблиці

Монограми з пробілами		Монограми без пробілів	
_	0,17253725	о	0,116651488
о	0,096524761	е	0,08863062
е	0,073338537	а	0,080997557
а	0,067022462	н	0,066178945
н	0,054760612	и	0,065936492
и	0,054559991	т	0,065838787
т	0,054479143	с	0,053819849
с	0,04453392	в	0,047038388
в	0,038922514	л	0,046733211
л	0,038669991	р	0,042534302
р	0,035195551	к	0,033581617
к	0,027787537	д	0,03255511
д	0,026938141	м	0,031967673
м	0,026452059	у	0,030149875
у	0,024947898	п	0,027902657
п	0,023088409	ь	0,023616899
ь	0,019542105	я	0,021723108
я	0,017975063	ч	0,018407165
ч	0,015231243	б	0,017681011
б	0,014630378	г	0,017174392
г	0,014211169	з	0,01565574
з	0,012954542	ж	0,011600374
ж	0,009598877	й	0,01018184
й	0,008425093	х	0,008651126
х	0,007158485	ш	0,008368867
ш	0,006924926	ю	0,005711529
ю	0,004726077	э	0,00358614
э	0,002967398	щ	0,003040922
щ	0,002516249	ц	0,002818974
ц	0,002332596	ф	0,001265342
ф	0,001047023		

Перехресні біграми з пробілами		Неперехресні біграми з пробілами		Перехресні біграми без пробілів		біграми без пробілів	
о_	0,0239	о_	0,0237571	то	0,018448	то	0,018436
е_	0,019144	е_	0,0191419	не	0,01296	не	0,013218
и_	0,017574	и_	0,017469	ов	0,012799	ов	0,012846
а_	0,017097	_в	0,0170957	на	0,012319	на	0,012393
в	0,016902	а	0,0169799	но	0,012143	но	0,012304
_п	0,016063	_п	0,0161954	ст	0,011828	ст	0,011874
_н	0,016003	_н	0,0161854	по	0,011074	по	0,011184
_с	0,015798	_с	0,015914	ко	0,010851	ко	0,010851
то	0,014845	то	0,0149218	он	0,010551	он	0,010545
ь_	0,01202	ь_	0,0120552	от	0,00991	от	0,009942

CoolPinkProgram

H10 = 2,65664976

R = 0,468670048

[illegible]

$$H_{20} = 2,583019735$$

$$R = 0,483396053$$

[illegible]

$$H_{30} = 1,96906159$$

$$R = 0.606187682$$

Произвольная часть текста:
аються_скажем_при_сложении_чис

Использованные буквы:

Порядок n-граммы:

- 5 символов
- 10 символов
- 15 символов
- 20 символов
- 25 символов
- 30 символов**
- 35 символов
- 40 символов
- 45 символов
- 50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 52

Неравенство для энтропии:
 $1,57709880554963 < H < 2,361024383957$

Двоичная таблица угаданных символов:

10000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
01000000000000000000000000000000
10000000000000000000000000000000

Вероятности:

q[1] = 0,569627450980392
q[2] = 0,156962745098039
q[3] = 0,0392156962745098
q[4] = 0,0196078431372549
q[5] = 0
q[6] = 0,0196078431372549
q[7] = 0,0196078431372549
q[8] = 0,0392156962745098
q[9] = 0
q[10] = 0,0196078431372549
q[11] = 0
q[12] = 0
q[13] = 0
q[14] = 0,0196078431372549
q[15] = 0
q[16] = 0,0196078431372549
q[17] = 0
q[18] = 0,0196078431372549
q[19] = 0,0196078431372549
q[20] = 0
q[21] = 0
q[22] = 0
q[23] = 0
q[24] = 0
q[25] = 0,0196078431372549
q[26] = 0
q[27] = 0
q[28] = 0
q[29] = 0
q[30] = 0
q[31] = 0,0196078431372549
q[32] = 0

Поле ввода символов:

Продолжить Другой

Строка состояния:

Висновок:

Найчастіший символ – пробіл, тому потрібно його прибирати при шифруванні.

Найчастіші букви – “о”, “е”, “а”, “и”. Найчастіші перехресні біграми в тексті з пробілами: “о “, “е “, “и “; перехресні: “о “, “е “, “ п“; перехресні без пробілів: “то”, “но”, “ст”; перехресні - аналогічно.